



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 1

Análisis Exploratorio e Inferencial (práctica)

Título del proyecto:	Predicción de Deserción y Éxito Académico en Educación Superior
Integrantes:	Alonso Arias, Enso Guidotti
Dataset:	Predict Students' Dropout and Academic Success (UCI, 2021)
Docente:	Jean Paul Maidana
Fecha:	26/06/2026
Repositorio GitHub:	https://github.com/EnsoG/mcdi501-grupo-4

Índice

1	Introducción	2
1.1	Contexto y origen del dataset	2
1.2	Descripción general	2
1.3	Propósito del proyecto	2
1.4	Clasificación y descripción de variables	2
1.5	Relaciones preliminares hipotizadas entre variables	4
2	Aplicación de estadística descriptiva	4
3	Estimación puntual e intervalos de confianza	5
4	Aplicación de una prueba de hipótesis	5
5	Documentación de procedimientos y resultados	5
6	Interpretación preliminar de resultados	6
7	Presentación formal del informe	6
	Bibliografía	6

1. Introducción

1.1 Contexto y origen del dataset

El dataset seleccionado es **Predict Students' Dropout and Academic Success**, creado por Realinho et al. (2021) en el Instituto Politécnico de Portalegre (Portugal) y publicado en el repositorio UCI Machine Learning Repository (DOI: 10.24432/C5MC89). El conjunto de datos surge de un proyecto cuyo objetivo es reducir el abandono académico y el fracaso en la educación superior mediante técnicas de aprendizaje automático, identificando estudiantes en riesgo en etapas tempranas de su trayectoria.

El dataset integra información de múltiples bases de datos institucionales, capturando el contexto completo del estudiante al momento de la matrícula: trayectoria académica previa, características demográficas y factores socioeconómicos. Adicionalmente, incluye el desempeño académico al final del primero y segundo semestre, junto con indicadores macroeconómicos del período de inscripción.

1.2 Descripción general

- **Instancias:** 4.424 estudiantes de educación superior
- **Variables:** 36 predictores + 1 variable objetivo
- **Tipo de problema:** clasificación ternaria original (Dropout / Enrolled / Graduate)
- **Adaptación para el proyecto:** se binariza la variable objetivo, conservando únicamente las clases *Dropout* (abandono = 0) y *Graduate* (graduado = 1), y excluyendo los estudiantes aún matriculados (*Enrolled*)
- **Datos faltantes:** el dataset está completamente limpio (sin valores nulos). Se generarán datos faltantes artificiales bajo mecanismo MCAR en 1–2 variables numéricas relevantes (10–15 %, `random_state=42`), guardando copia de los valores originales para evaluar la imputación
- **Licencia:** Creative Commons Attribution 4.0 International (CC BY 4.0)
- **Fuente:** <https://archive.ics.uci.edu/dataset/697>

1.3 Propósito del proyecto

El proyecto busca responder la siguiente pregunta de investigación: **¿Qué factores demográficos, socioeconómicos y de desempeño académico permiten predecir si un estudiante de educación superior abandonará sus estudios o se graduará?**

Este problema tiene alta relevancia práctica: la deserción estudiantil afecta a individuos, instituciones y sistemas educativos. Un modelo predictivo temprano permite diseñar intervenciones focalizadas (tutorías, becas, apoyo psicosocial) antes de que el abandono se concrete.

1.4 Clasificación y descripción de variables

El dataset contiene 37 variables en total, organizadas en seis grupos temáticos. La Tabla 1 presenta la clasificación estadística de cada una.

Tabla 1: Clasificación estadística de las variables del dataset.

Variable	Tipo estadístico	dtype pandas	Rango / Categ.
A. Variables demográficas			
Estado civil (<i>Marital status</i>)	Cualit. nominal	category	6 categorías
Nacionalidad (<i>Nationality</i>)	Cualit. nominal	category	21 países
Género (<i>Gender</i>)	Cualit. nominal (bin.)	category	Fem. / Masc.
Edad al inscribirse	Cuant. discreta	int64	17–70 años
Estudiante desplazado	Cualit. nominal (bin.)	category	Sí / No
Necesidades educ. especiales	Cualit. nominal (bin.)	category	Sí / No
Internacional (<i>International</i>)	Cualit. nominal (bin.)	category	Sí / No
B. Variables académicas previas			
Modo de postulación	Cualit. nominal	category	17 categorías
Orden de postulación	Cuant. discreta	int64	0–9
Carrera (<i>Course</i>)	Cualit. nominal	category	17 carreras
Modalidad de asistencia	Cualit. nominal (bin.)	category	Diurno / Vesp.
Calificación previa — tipo	Cualit. ordinal	category	13 niveles
Calificación previa — nota	Cuant. continua	float64	0–200
Nota de admisión	Cuant. continua	float64	0–200
C. Variables socioeconómicas			
Nivel educativo madre	Cualit. ordinal	category	24 niveles
Nivel educativo padre	Cualit. ordinal	category	24 niveles
Ocupación madre	Cualit. nominal	category	Múlt. categ.
Ocupación padre	Cualit. nominal	category	Múlt. categ.
Becado (<i>Scholarship holder</i>)	Cualit. nominal (bin.)	category	Sí / No
Deudor (<i>Debtor</i>)	Cualit. nominal (bin.)	category	Sí / No
Matrícula al día	Cualit. nominal (bin.)	category	Sí / No
D. Desempeño académico — 1er semestre			
UC 1S acreditadas	Cuant. discreta	int64	≥ 0
UC 1S inscritas	Cuant. discreta	int64	≥ 0
UC 1S con evaluaciones	Cuant. discreta	int64	≥ 0
UC 1S aprobadas	Cuant. discreta	int64	≥ 0
Calificación promedio 1S	Cuant. continua	float64	0–20
UC 1S sin evaluaciones	Cuant. discreta	int64	≥ 0
D. Desempeño académico — 2do semestre			
UC 2S acreditadas	Cuant. discreta	int64	≥ 0
UC 2S inscritas	Cuant. discreta	int64	≥ 0
UC 2S con evaluaciones	Cuant. discreta	int64	≥ 0
UC 2S aprobadas	Cuant. discreta	int64	≥ 0

continúa en la página siguiente

(continuación de Tabla 1)

Variable	Tipo estadístico	dtype pandas	Rango / Categ.
Calificación promedio 2S	Cuant. continua	float64	0–20
UC 2S sin evaluaciones	Cuant. discreta	int64	≥ 0
E. Variables macroeconómicas			
Tasa de desempleo	Cuant. continua	float64	% anual
Tasa de inflación	Cuant. continua	float64	% anual
PIB (<i>GDP</i>)	Cuant. continua	float64	variación %
F. Variable objetivo			
Situación académica (<i>Target</i>)	Cualit. nominal (bin.)	category	Dropout (0) / Graduate (1)

1.5 Relaciones preliminares hipotizadas entre variables

Con base en la literatura sobre deserción estudiantil y la naturaleza de las variables, se plantean las siguientes relaciones de interés que guiarán el análisis:

1. **Rendimiento académico** $\rightarrow$ **Deserción**: se espera que estudiantes con menor número de UC aprobadas en el primer semestre tengan mayor probabilidad de abandono.
2. **Situación financiera** $\rightarrow$ **Deserción**: las variables *Deudor* y *Matrícula al día* se hipotetiza que tienen asociación directa con el abandono por barreras económicas.
3. **Becado** $\rightarrow$ **Graduación**: se espera asociación positiva entre recibir beca y lograr la graduación, dado el apoyo financiero que reduce el estrés económico.
4. **Edad al inscribirse** $\rightarrow$ **Deserción**: estudiantes que ingresan a mayor edad (especialmente en modalidad vespertina) pueden tener mayores compromisos laborales o familiares.
5. **Nota de admisión** $\rightarrow$ **Rendimiento**: se espera correlación positiva entre la nota de admisión y las calificaciones semestrales.
6. **Contexto macroeconómico** $\rightarrow$ **Deserción**: la relación entre tasa de desempleo y deserción puede ser ambigua; su sentido neto se determinará empíricamente.
7. **Nivel educativo parental** $\rightarrow$ **Permanencia**: mayor nivel educativo de los padres se asocia, según la literatura, con mayor probabilidad de graduación.

2. Aplicación de estadística descriptiva

El análisis descriptivo se estructurará en dos etapas:

Etapla 1: Variables numéricas. Para cada variable cuantitativa continua y discreta (nota de admisión, calificación previa, edad, calificaciones semestrales, UC aprobadas, variables macroeconómicas) se calcularán:

- Tendencia central: media aritmética y mediana
- Dispersión: desviación estándar, coeficiente de variación (CV) y rango intercuartil (IQR)
- Forma: coeficiente de asimetría (*skewness*) y curtosis
- Visualizaciones: histogramas con curva de densidad y boxplots, segmentados por clase objetivo (Dropout vs. Graduate)

Etapla 2: Variables categóricas. Para variables como género, modalidad de asistencia, beca, deudor, matrícula al día y carrera se calcularán frecuencias absolutas y relativas, con visualizaciones de barras apiladas por clase objetivo.

El análisis bivariado incluirá una matriz de correlación de Pearson para variables numéricas y tablas de contingencia para pares categórico-categórico relevantes (e.g., beca vs. resultado; modalidad vs. resultado).

3. Estimación puntual e intervalos de confianza

Se estimarán parámetros para al menos tres variables numéricas relevantes:

1. **Calificación promedio del 1er semestre:** estimación de la media poblacional con IC al 95 % mediante distribución t de Student, separadamente para Dropout y Graduate para comparar.
2. **Número de UC aprobadas en 2do semestre:** estimación de la media con IC al 95 %. Se espera diferencia marcada entre clases; esta variable es clave para el modelo predictivo.
3. **Edad al inscribirse:** estimación de media poblacional con IC al 95 %, explorando si la distribución etaria difiere entre clases.

Para cada variable se reportará el estimador puntual (media muestral), el error estándar, el margen de error y el intervalo $[\bar{x} - t_{\alpha/2} \cdot SE, \bar{x} + t_{\alpha/2} \cdot SE]$, junto con su interpretación en el contexto del problema.

4. Aplicación de una prueba de hipótesis

Prueba 1 - Diferencia de medias en UC aprobadas (1er semestre):

¿El promedio de UC aprobadas en el primer semestre difiere significativamente entre estudiantes que desertan y los que se gradúan?

$$H_0: \mu_{\text{Dropout}} = \mu_{\text{Graduate}} \quad H_1: \mu_{\text{Dropout}} < \mu_{\text{Graduate}}$$

Prueba t de Welch para muestras independientes con varianzas desiguales ($\alpha = 0,05$). Se verificará normalidad mediante Shapiro-Wilk; si se rechaza, se usará Mann-Whitney U.

Prueba 2 - Proporción de becados entre clases:

¿La proporción de becados es estadísticamente diferente entre estudiantes que desertan y los que se gradúan?

$$H_0: p_{\text{Dropout}} = p_{\text{Graduate}} \quad H_1: p_{\text{Dropout}} \neq p_{\text{Graduate}}$$

Prueba χ^2 de independencia (tabla de contingencia 2×2) con $\alpha = 0,05$.

5. Documentación de procedimientos y resultados

El análisis seguirá el flujo estándar del curso:

1. **Carga y verificación:** lectura del CSV con `pandas`, verificación de tipos (`.info()`), estadísticos iniciales (`.describe()`) y revisión de valores únicos en variables categóricas

2. **Generación de faltantes artificiales:** selección de 2 variables numéricas (calificación 1S y nota de admisión), eliminación MCAR del 12 % de valores con `random_state=42`, guardado de copia completa
3. **Binarización del target:** filtrado de filas *Enrolled*, recodificación Dropout=0 / Graduate=1
4. **Análisis descriptivo:** cálculo de estadísticos con `pandas/numpy`, visualizaciones con `seaborn/matplotlib`
5. **Estimación e IC:** cálculo de intervalos con `scipy.stats.t.interval()`
6. **Pruebas de hipótesis:** ejecución con `scipy.stats.ttest_ind` y `scipy.stats.chi2_contingency`

El notebook `.ipynb` estará organizado en secciones con celdas Markdown explicativas para cada etapa, código documentado con comentarios inline y visualizaciones con títulos y etiquetas en español.

6. Interpretación preliminar de resultados

Se espera que **el rendimiento del primer semestre sea el predictor más diferenciador**: estudiantes que abandonan probablemente aprueban significativamente menos UC que los que se gradúan, incluso en el primer semestre. Esta señal temprana es valiosa porque permite intervención antes del segundo semestre.

La **situación financiera** (matrícula al día, deudor, beca) debería mostrar asociación clara con el resultado: el acceso a beca actuaría como factor protector. Esta relación es relevante para políticas institucionales de apoyo económico focalizado.

Los **factores macroeconómicos** podrían mostrar una relación ambigua: en períodos de alto desempleo, el costo de oportunidad de estudiar disminuye (menor abandono), pero la presión financiera familiar aumenta (mayor abandono). El sentido neto de la relación se determinará empíricamente.

Se anticipa que el **modelo final presentará clases desbalanceadas**: la tasa de deserción en educación superior portuguesa es inferior a la tasa de graduación, lo que requerirá estrategias de balanceo en etapas posteriores del proyecto.

7. Presentación formal del informe

Este informe sigue los lineamientos formales establecidos por el curso: redacción en español académico, uso consistente de terminología estadística, tablas y referencias numeradas, y estructura según la plantilla oficial. La Tabla 1 presenta la clasificación completa de variables con nomenclatura estadística precisa (cualitativa/cuantitativa, nominal/ordinal/discreta/continua), en concordancia con el apunte del curso *Tipos de variables y exploración de datos con pandas* (Maidana, 2026).

El repositorio GitHub del proyecto contendrá el notebook reproducible, el dataset procesado (con faltantes artificiales), y este informe en PDF. Todos los resultados serán trazables desde el código a la interpretación.

Bibliografía

- Maidana, J. P. (2026). *Tipos de variables y exploración de datos con pandas* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Bases de datos disponibles para el proyecto del curso* [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict Students' Dropout and Academic Success* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146. <https://doi.org/10.3390/data7110146>