



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Título del proyecto: Predicción de Deserción y Éxito Académico en Educación Superior
Integrantes: Alonso Arias, Enso Guidotti
Dataset: Predict Students' Dropout and Academic Success (UCI, 2022)
Docente: Jean Paul Maidana
Fecha: 30/06/2026
Repositorio GitHub: <https://github.com/EnsoG/mcdi501-grupo-4>

Índice

1 Preparación y carga de datos	2
2 Análisis exploratorio de datos	2
2.1 Estadística descriptiva	2
2.2 Visualizaciones	2
2.3 Variables categóricas	2
2.4 Matriz de correlación	2
3 Estimación de parámetros	3
4 Pruebas de hipótesis	3
4.1 Prueba 1 - t de Welch: UC aprobadas en 2.º semestre	4
4.2 Prueba 2 - χ^2 : Beca vs Resultado	4
4.3 Prueba 3 - χ^2 : Matrícula al día vs Resultado	5
5 Informe de avance del proyecto	5
6 Notebook y repositorio GitHub	6
7 Bibliografía (APA 7)	6

1. Preparación y carga de datos

Se utilizó el dataset *Predict Students' Dropout and Academic Success* [5], disponible en UCI Machine Learning Repository. El archivo `data.csv` emplea punto y coma como separador; los nombres de columna presentaban un carácter de tabulación residual eliminado con `strip()`. La carga se realizó con `pandas.read_csv(sep=',')`.

Verificación de calidad inicial: el dataset original contiene 4.424 registros y 35 columnas con 0 valores faltantes y 0 filas duplicadas. Todos los tipos de datos son numéricos (`int64` y `float64`).

Binarización del target: la variable objetivo original tiene tres clases. Se excluyeron 794 estudiantes en curso (*Enrolled*), resultando en **3.630 registros**: Dropout = 1.421 (39,1 %) y Graduate = 2.209 (60,9 %). Se asignó Dropout = 0 y Graduate = 1.

Faltantes artificiales MCAR: se inyectó un 12 % de valores faltantes bajo mecanismo MCAR (`random_state=42`) en *Curricular units 1st sem (grade)* y *Admission grade*. Se conservó copia completa de los valores originales (`df_original`) para evaluación de imputación en la Sumativa 2.

2. Análisis exploratorio de datos

2.1 Estadística descriptiva

Se analizaron 10 variables numéricas. Hallazgos principales:

- **UC aprobadas 2S:** fuerte asimetría positiva ($\text{skewness} > 2$). Dropout: media = 1,94 UC; Graduate: media = 6,18 UC. Diferencia de 4,2 UC entre grupos.
- **Calificación 2S:** distribución bimodal entre clases. Dropout: media = 5,9, std = 5,9; Graduate: media = 12,7, std = 2,2. Alta heterogeneidad interna en desertores.
- **Edad al inscribirse:** asimetría positiva (mediana 21 años, media 23 años). Desertores 4,3 años mayores en promedio (26,1 vs 21,8).
- **Nota de admisión:** distribución simétrica ($\text{skewness} \approx 0$). Diferencia modesta entre clases (125,0 vs 128,7 en escala 0–200).
- **Macroeconómicas** (desempleo, inflación, PIB): baja varianza, correlación con target ≈ 0 .

2.2 Visualizaciones

Los boxplots (Figura 1) confirman las diferencias: para UC aprobadas 2S y Calificación 2S las cajas no se solapan; para Edad hay solapamiento parcial; para Nota de admisión las cajas se solapan considerablemente.

2.3 Variables categóricas

Las variables socioeconómicas (Figura 2) muestran asociaciones marcadas:

- **Becado:** 86,2 % de becados se gradúa vs 51,6 % de no becados. La beca actúa como factor protector.
- **Matrícula al día:** 69,3 % con matrícula al día se gradúa vs solo 6,0 % con matrícula impaga. Predictor categórico más diferenciador.
- **Deudor:** tasa de deserción sustancialmente mayor; consistente con el efecto de matrícula.

2.4 Matriz de correlación

Correlaciones con `Target_bin`: UC aprobadas 2S ($r = 0,654$), Calificación 2S ($r = 0,605$), UC aprobadas 1S ($r = 0,555$), Edad ($r = -0,267$), Nota de admisión ($r = 0,101$). Variables




Figura 1: Distribución de variables numéricas clave por clase objetivo.




Figura 2: Variables socioeconómicas por clase objetivo (% dentro de cada clase).

macroeconómicas: $r \approx 0$. Se detecta **multicolinealidad potencial** entre UC 1S y UC 2S ($r \approx 0,7$), a considerar en Sumativa 3.

3. Estimación de parámetros

Se estimaron medias poblacionales con IC al 95 % usando t de Student (`scipy.stats.t.interval`), σ desconocida, bilateral, $\alpha = 0,05$. Con $n > 1.000$ en cada grupo la diferencia respecto a Z es despreciable.

En las tres primeras variables los IC no se solapan, confirmando diferencias poblacionales significativas. Para Nota de admisión los IC son adyacentes sin solapamiento; la diferencia práctica es modesta (3,7 puntos en escala 0–200).

Limitación: la Nota de admisión se estimó sobre muestras reducidas por los faltantes MCAR. Si el mecanismo no fuera completamente aleatorio los estimadores podrían estar sesgados; esto se evaluará en la Sumativa 2.

4. Pruebas de hipótesis

Se aplicaron tres pruebas con $\alpha = 0,05$, equilibrando error Tipo I y Tipo II en un contexto de apoyo académico.




Figura 3: Matriz de correlación entre variables numéricas clave y Target_bin.

Variable	Clase	n	Media	IC inf	IC sup
UC aprobadas 2S	Dropout	1.421	1,940	1,806	2,074
	Graduate	2.209	6,177	6,082	6,272
Calificación 2S	Dropout	1.421	5,899	5,581	6,218
	Graduate	2.209	12,697	12,585	12,809
Edad al inscribirse	Dropout	1.421	26,069	25,616	26,522
	Graduate	2.209	21,784	21,504	22,063
Nota de admisión	Dropout	1.254*	125,028	124,193	125,864
	Graduate	1.941*	128,701	128,076	129,327

*n reducido por 435 faltantes MCAR (12 %).

Tabla 1: IC al 95 % por clase objetivo (t de Student, bilateral).

4.1 Prueba 1 - t de Welch: UC aprobadas en 2.^o semestre

$H_0: \mu_{\text{Dropout}} = \mu_{\text{Graduate}}$ vs $H_1: \mu_{\text{Dropout}} < \mu_{\text{Graduate}}$ (unilateral izquierda)

Supuestos: Shapiro-Wilk rechaza normalidad en ambos grupos, pero $n > 1.000$ garantiza la validez por TLC. Varianzas desiguales $\rightarrow$ variante de Welch (equal_var=False).

Resultado: $t = -50,67$, $p \approx 0 \ll \alpha$. **Se rechaza H_0 .**

Los desertores aprueban 1,94 UC vs 6,18 UC los graduados. La diferencia de 4,2 UC es accionable como señal de alerta temprana al cierre del 2.^o semestre.

4.2 Prueba 2 - χ^2 : Beca vs Resultado

H_0 : Beca y resultado son independientes vs H_1 : Existe asociación




Figura 4: Intervalos de confianza al 95 % por variable y clase objetivo.

Supuesto: frecuencias esperadas > 5 (verificado). Tabla 2×2 .

Resultado: $\chi^2(1) = 354,22$, $p = 5,1 \times 10^{-79}$, $V_{\text{Cramér}} = 0,31$. **Se rechaza H_0 .**

El 86,2 % de becados se gradúa vs el 51,6 % de no becados. Asociación moderada: la beca actúa como factor protector y será incluida como predictor en la Sumativa 3.

4.3 Prueba 3 - χ^2 : Matrícula al día vs Resultado

H_0 : Matrícula y resultado son independientes vs H_1 : Existe asociación

Supuesto: frecuencias esperadas > 5 (verificado). Tabla 2×2 .

Resultado: $\chi^2(1) = 706,96$, $p = 9,2 \times 10^{-156}$, $V_{\text{Cramér}} = 0,44$. **Se rechaza H_0 .**

El 69,3 % con matrícula al día se gradúa vs solo el 6,0 % con matrícula impaga. Es el predictor categórico más potente: la matrícula impaga es un indicador casi determinante de deserción.

5. Informe de avance del proyecto

Introducción: Se analizó el dataset *Predict Students' Dropout and Academic Success* [6] con el objetivo de identificar factores asociados a la deserción para apoyar intervención temprana. El análisis se realizó sobre 3.630 registros (Dropout = 1.421, Graduate = 2.209).

Métodos aplicados: binarización del target y generación de faltantes MCAR 12 % con semilla fija; estadística descriptiva con medidas de tendencia central, dispersión y forma; visualizaciones bivariadas (boxplots, histogramas, barras, correlación); IC al 95 % con t de Student para 4 variables; tres pruebas de hipótesis (t Welch y χ^2) con verificación de supuestos y tamaño del efecto.

Resultados clave: los predictores más fuertes son UC aprobadas 2S ($r = 0,654$) y Calificación 2S ($r = 0,605$). El estado de matrícula es el predictor categórico más potente ($V = 0,44$). Las tres pruebas rechazan H_0 con evidencia muy sólida ($p \ll \alpha$ en todos los casos).

Próximos pasos: Sumativa 2: imputación de faltantes (media, mediana, KNN) y validación Bootstrap. Sumativa 3: modelamiento predictivo con regresión logística y árbol de decisión sobre los predictores identificados.

6. Notebook y repositorio GitHub

El notebook `sumativa_1.ipynb` está completamente ejecutado y disponible en <https://github.com/EnsoG/mcdi501-grupo-4>. Contiene las secciones: importación de librerías, preparación de datos, EDA, estimación de parámetros, pruebas de hipótesis, conclusiones y bibliografía. Las figuras se exportan en `docs/sumativa1/` con `dpi=150`. El archivo `requirements.txt` especifica las dependencias del entorno.

7. Bibliografía (APA 7)

Bibliografía

- [1] Maidana, J. P. (2026). *Medidas de tendencia central: media, mediana y moda* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- [2] Maidana, J. P. (2026). *Medidas de dispersión y forma: variabilidad, asimetría y curtosis* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- [3] Maidana, J. P. (2026). *Intervalos de confianza: cuantificando la incertidumbre estadística* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- [4] Maidana, J. P. (2026). *Pruebas de hipótesis: pruebas t y Z para una muestra* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- [5] Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict Students' Dropout and Academic Success* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>
- [6] Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146. <https://doi.org/10.3390/data7110146>
- [7] Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... & van der Walt, S. J. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>