



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal · 20 %

Título del proyecto: Predicción de Deserción y Éxito Académico en Educación Superior
Integrantes: Alonso Arias, Enso Guidotti
Dataset: Predict Students' Dropout and Academic Success (UCI, Realinho et al., 2021)
Docente: Jean Paul Maidana
Fecha: 03/07/2026
Repositorio GitHub: <https://github.com/EnsoG/mcdi501-grupo-4>

Información de la evaluación

Fase del proyecto: Fase 3: Desarrollo del proyecto

Modalidad: Grupal **Ponderación:** 20 % de la nota final

Resultado de aprendizaje (RA2): implementar métodos computacionales de simulación y remuestreo para apoyar la toma de decisiones en escenarios complejos.

Conexión con evaluaciones anteriores

Todo el análisis de este informe se construye directamente sobre los resultados de la Sumativa 1: 3.630 estudiantes post-binarización (Dropout=1.421, Graduate=2.209), semilla `random_state=42`, e IC clásicos, pruebas de hipótesis y correlaciones allí obtenidas.

Índice

1	Introducción	1
2	Validación de resultados de S1 mediante bootstrap	1
3	Validación de pruebas de hipótesis mediante permutación	2
4	Evaluación de estabilidad de correlaciones	3
5	Simulación Monte Carlo basada en parámetros de S1	3
6	Análisis de robustez	4
7	Preparación para la Sumativa 3	4
8	Bibliografía (APA 7ª edición)	5

1. Introducción

Este informe corresponde a la Evaluación Sumativa 2 del curso MCDI501, enmarcada en la Fase 3 (Desarrollo del proyecto) del trabajo sobre el dataset *Predict Students' Dropout and Academic Success* (Realinho et al., 2021). Su objetivo es implementar métodos computacionales de simulación y remuestreo que validen y profundicen la robustez de los resultados obtenidos en la Sumativa 1: los parámetros estimados, los intervalos de confianza, las pruebas de hipótesis y las correlaciones calculadas sobre la muestra de 3.630 estudiantes (Dropout=1.421, Graduate=2.209).

El documento se organiza como sigue. La Sección 2 valida los intervalos de confianza clásicos de S1 mediante bootstrap no paramétrico (percentil y BCa). La Sección 3 contrasta la principal prueba de hipótesis de S1 con un test de permutación. La Sección 4 evalúa la estabilidad de cinco correlaciones relevantes mediante IC bootstrap. La Sección 5 diseña una simulación Monte Carlo basada exclusivamente en parámetros estimados en S1. La Sección 6 analiza la sensibilidad de los resultados frente a outliers y supuestos estadísticos mediante jackknife y bootstrap. Finalmente, la Sección 7 sintetiza los parámetros robustos, las correlaciones estables y las recomendaciones metodológicas que constituyen el insumo directo para la Sumativa 3.

2. Validación de resultados de S1 mediante bootstrap

Bootstrap no paramétrico (≥ 10.000 remuestras) para 3 parámetros de S1, IC percentil y BCa vs. IC clásico.

Se validaron las medias de tres variables clave de S1 (UC aprobadas 2do semestre, Calificación 2do semestre y Edad al inscribirse), separadas por clase, con bootstrap no paramétrico de 10.000 remuestras.

Análisis: los tres métodos producen intervalos casi idénticos (diferencias de ancho $< 3\%$) porque el tamaño muestral es grande (n entre 1.421 y 2.209 por grupo): el TCL garantiza que la media muestral es aproximadamente normal aunque los datos originales no lo sean, validando el uso del IC clásico de S1. La corrección BCa no desplaza apreciablemente el intervalo, indicando sesgo despreciable. La mayor diferencia relativa aparece en Calificación 2S-Dropout, la variable más dispersa y asimétrica, donde el bootstrap ajusta levemente el intervalo sin cambiar la conclusión. **Conclusión:** los IC clásicos de S1 quedan validados; el bootstrap sería indispensable solo con submuestras pequeñas ($n < 50$).

Variable	Clase	Media	IC clásico	IC percentil	IC BCa
UC aprobadas 2S	Dropout	1.940	[1.806, 2.074]	[1.811, 2.075]	[1.809, 2.075]
UC aprobadas 2S	Graduate	6.177	[6.082, 6.272]	[6.083, 6.272]	[6.083, 6.270]
Calificación 2S	Dropout	5.899	[5.581, 6.218]	[5.591, 6.221]	[5.582, 6.212]
Calificación 2S	Graduate	12.697	[12.585, 12.809]	[12.585, 12.808]	[12.580, 12.803]
Edad al inscribirse	Dropout	26.069	[25.616, 26.522]	[25.619, 26.510]	[25.626, 26.517]
Edad al inscribirse	Graduate	21.784	[21.504, 22.063]	[21.508, 22.070]	[21.515, 22.074]

Tabla 1: Comparación de IC 95% clásico vs. bootstrap (percentil y BCa), 10.000 remuestras.




Figura 1: Distribuciones bootstrap de la media (10.000 remuestras) con IC clásico y BCa superpuestos.

Validación adicional: robustez frente a la imputación MCAR. S1 preservó los valores originales de las dos variables con faltantes artificiales (Curricular units 1st sem (grade) y Admission grade) antes de inyectar el patrón MCAR. Se comparó, mediante bootstrap, la media de cada variable imputada por media, mediana y KNN ($k = 5$) contra el valor de referencia (ground truth) de los datos completos originales.

Variable	Método	Media imputada	Sesgo	¿Original en IC 95%?
UC 1S (nota)	Media	10.529	-0.05 %	Sí
UC 1S (nota)	Mediana	10.750	+2.05 %	No
UC 1S (nota)	KNN	10.530	-0.05 %	Sí
Nota de admisión	Media	127.260	-0.03 %	Sí
Nota de admisión	Mediana	127.169	-0.10 %	Sí
Nota de admisión	KNN	127.352	+0.05 %	Sí

La imputación por media y por KNN preservan la media original en ambas variables (sesgo $< 0.1\%$, valor original siempre dentro del IC bootstrap). La mediana, en cambio, introduce un sesgo detectable en UC 1S-nota (+2.05 %, el valor original queda fuera del IC), porque esta variable concentra valores bajos/cero (estudiantes sin evaluación rendida), similar al patrón de UC aprobadas 2S en Dropout (Sección 6). **Conclusión:** media o KNN son seguros para imputar estas variables en S3; la mediana debe evitarse en variables con alta concentración de valores bajos.

3. Validación de pruebas de hipótesis mediante permutación

Test de permutación (≥ 10.000 permutaciones) sobre la Prueba 1 de S1, comparación de valores p.

Se validó la Prueba 1 de S1 (t de Welch, unilateral: ¿Dropout aprueba menos UC en 2do semestre que

Graduate?) mediante 10.000 permutaciones de las etiquetas de clase.

Enfoque	Estadístico	<i>p</i> -valor
Paramétrico (t de Welch, S1)	$t = -50.671$	$\approx 0 (1.6 \times 10^{-315})$
Permutación (10.000 iter.)	diff. medias = -4.237	9.999×10^{-5}

Concordancia: ambos enfoques rechazan H_0 con altísima confianza; el *p*-valor de permutación alcanza el mínimo resoluble con 10.000 iteraciones (ninguna reordenación aleatoria igualó la diferencia observada). El test de permutación no exige normalidad ni varianzas iguales, solo intercambiabilidad bajo H_0 , por lo que es más robusto frente a la fuerte asimetría de esta variable (conteo discreto concentrado en 0 para Dropout). Que ambos coincidan respalda la conclusión de S1: se recomienda reportar el *p* paramétrico (más preciso) y usar la permutación como validación independiente de robustez.

4. Evaluación de estabilidad de correlaciones

IC bootstrap 95% (percentil, 10.000 remuestras) para 5 correlaciones de S1.

Variable	<i>r</i>	IC 95%	Ancho	¿Incluye 0?
UC aprobadas 2S	0.654	[0.631, 0.677]	0.046	No
Calificación 2S	0.605	[0.581, 0.629]	0.047	No
UC aprobadas 1S	0.555	[0.529, 0.581]	0.052	No
Edad al inscribirse	-0.267	[-0.299, -0.235]	0.064	No
Nota de admisión	0.123	[0.087, 0.158]	0.071	No

Las 5 correlaciones son **robustas**: ningún IC cruza el cero, con anchos pequeños (0.046-0.071) por el tamaño muestral grande. **Discrepancia detectada:** el texto de S1 reportó $r = 0.101$ para Nota de admisión; el recálculo exacto da $r = 0.123$ (IC [0.087, 0.158]), diferencia atribuible a un redondeo aproximado de la tabla resumen de S1. No cambia la conclusión cualitativa: sigue siendo la correlación más débil e inestable en términos relativos. UC aprobadas y Calificación (1S y 2S) son las correlaciones más fuertes y estables, candidatas prioritarias para S3.




Figura 2: IC bootstrap 95% de correlaciones con el resultado académico.

5. Simulación Monte Carlo basada en parámetros de S1

Simulación con ≥ 10.000 iteraciones usando exclusivamente parámetros de S1, evaluación de convergencia.

Escenario: se proyectó la tasa de graduación de una cohorte de tamaño $n=3.630$, usando exclusivamente la distribución conjunta observada de Beca y Matrícula al día (los predictores categóricos más fuertes de S1: $\chi^2 = 354.2$ y $\chi^2 = 706.9$ respectivamente) y la probabilidad de graduarse condicional a cada una de sus 4 combinaciones. La justificación es verificar si estas dos variables, por sí solas, reproducen la tasa de graduación real observada. Cabe precisar que S1 reportó únicamente los estadísticos de asociación (χ^2) de estas variables con el target; las probabilidades conjuntas y condicionales por celda usadas como insumo de la simulación se calculan aquí directamente sobre la misma muestra de S1, y son consistentes con, aunque no idénticas a, los estadísticos allí reportados.

Con 10.000 iteraciones, la tasa media simulada fue 0.6087 (DE=0.00812), IC 95 % percentil [0.5928, 0.6245], y la tasa real observada (0.6085) cae en el centro del intervalo. La media acumulada se estabiliza antes de las 2.000 iteraciones y el error estándar decrece siguiendo la ley $1/\sqrt{n}$ (pendiente -0.5 en escala log-log), confirmando que 10.000 iteraciones son más que suficientes.




Figura 3: Distribución Monte Carlo, convergencia de la media acumulada y SE vs. n .

Interpretación: el modelo generativo simplificado (solo Beca y Matrícula al día) captura correctamente la tasa agregada real, aun ignorando el resto de las variables. El ancho del IC simulado (0.032) cuantifica la incertidumbre esperable por azar muestral en una cohorte finita; desviaciones futuras fuera de este rango sugerirían que un modelo predictivo no captura bien la heterogeneidad real de la población, información relevante para validar el modelo de S3.

6. Análisis de robustez

Sensibilidad a outliers y supuestos mediante jackknife, bootstrap y comparación de estadísticos.

1. **Jackknife de la media** (UC aprobadas 2S, Dropout): sesgo estimado prácticamente nulo, SE jackknife (0.0683) casi idéntico al SE bootstrap (0.0685). Estimador estable; ninguna observación domina el resultado (máxima influencia individual: estudiantes con 12-16 UC aprobadas).
2. **Jackknife de la correlación** (UC 2S vs. Target): $r = 0.654$ varía como máximo 0.0026 al remover cualquier observación individual; extremadamente robusta dado $n=3.630$.
3. **Sensibilidad a outliers:** al recortar el 1 %-99 % de UC aprobadas 2S (Dropout), la media cae de 1.940 a 1.830 (-5.7%). A diferencia de la correlación, **la media sí es sensible** a la cola superior (desertores con muchas UC aprobadas, casos atípicos dentro de su clase). La conclusión cualitativa no cambia, pero el valor puntual requiere cautela.
4. **Media vs. mediana:** la mediana de UC aprobadas 2S en Dropout es 0 (51.9 % de los desertores aprobó 0 unidades), con IC bootstrap inestable [0, 1] (ancho=1.0). La media resulta, en este caso, un resumen más informativo que la mediana pese a ser tradicionalmente menos "robusta" a outliers, ilustrando que la elección del estadístico debe basarse en la forma real de los datos.

Conclusiones confiables: diferencias Dropout/Graduate en UC aprobadas y Calificación 2S, correlaciones con el target, efecto protector de Beca/Matrícula al día. **Requieren cautela:** el valor puntual exacto de la media de UC aprobadas en Dropout (sensible en $\sim 6\%$ a la cola superior) y cualquier uso de la mediana como resumen de esa variable en el grupo Dropout.

7. Preparación para la Sumativa 3

Reporte de resultados validados: parámetros robustos, correlaciones estables, observaciones influyentes y recomendaciones metodológicas.

Parámetros robustamente estimados: medias de UC aprobadas y Calificación (1S/2S) y Edad por clase (Sección 2); diferencia de UC aprobadas 2S validada por permutación ($p < 0.0001$, ambos enfoques).

Correlaciones estables: UC aprobadas 2S ($r = 0.654$), Calificación 2S ($r = 0.605$), UC aprobadas 1S ($r = 0.555$), Edad ($r = -0.267$); Nota de admisión ($r = 0.123$) es la más débil e inestable relativamente.

Observaciones influyentes: la media de UC aprobadas 2S en Dropout es sensible a outliers altos ($\sim 5.7\%$ de cambio); la mediana no es un resumen útil para esta variable en Dropout por la alta concentración en cero.

Recomendaciones para S3: (1) usar Beca y Matrícula al día como variables base del modelo predictivo,

dado que su efecto conjunto ya reproduce la tasa de graduación real (validado por Monte Carlo); (2) UC aprobadas 1S y 2S están altamente correlacionadas entre sí ($r = 0.92$, recalculado directamente; más alto que el $r \approx 0.7$ estimado de forma aproximada en S1): usar solo UC aprobadas 2S (mayor correlación con el target, $r = 0.654$) o combinarlas en un único indicador, junto con Calificación 2S como predictor numérico adicional; (3) reportar coeficientes del modelo con IC bootstrap, no solo el valor puntual; (4) validar el modelo predictivo con remuestreo (validación cruzada o bootstrap de splits), replicando el enfoque de simulación usado aquí; (5) evitar la mediana como resumen de variables con alta concentración en cero.

8. Bibliografía (APA 7^a edición)

- Efron, B., & Tibshirani, R. J. (1994). *An introduction to the bootstrap*. Chapman & Hall/CRC.
- Maidana, J. P. (2026). *Bootstrap para intervalos de confianza: métodos Percentil, BCa e implementaciones* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Introducción a la simulación Monte Carlo* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Análisis de convergencia y precisión* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict Students' Dropout and Academic Success* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>
- Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146. <https://doi.org/10.3390/data7110146>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... & van der Walt, S. J. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261-272. <https://doi.org/10.1038/s41592-019-0686-2>