



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Informe técnico grupal · 60 %

Título del proyecto: Predicción temprana de deserción estudiantil: modelamiento predictivo integrado
Integrantes: Alonso Arias, Enso Guidotti
Dataset: Predict Students' Dropout and Academic Success (UCI, dataset 8)
Docente: Jean Paul Maidana
Fecha: 13/07/2026
Repositorio GitHub: <https://github.com/EnsoG/mcdi501-grupo-4>

Resumen ejecutivo. Se analiza el dataset *Predict Students' Dropout and Academic Success* (3.630 estudiantes, tras binarizar Dropout/Graduate) para identificar predictores de deserción y construir un modelo de alerta temprana. Partiendo de las correlaciones y pruebas de hipótesis de S1 y de las correcciones y validaciones de S2 (colinealidad UC1S-UC2S corregida de ~ 0.7 a 0.92 ; sensibilidad de la media a outliers de -5.7%), se imputan por regresión lineal las dos variables con faltantes MCAR (12% , `random_state=42`) y se construyen tres modelos de regresión logística. El modelo final (selección stepwise, idéntico al obtenido por criterio BIC, 9 variables) alcanza $AUC = 0.944$ y $\text{recall} = 0.962$ en test, superando al modelo basado únicamente en los 5 predictores fijos de S1/S2 ($AUC = 0.926$). El bootstrap de 1.000 remuestras confirma la estabilidad de sus coeficientes. La estrategia de imputación elegida (regresión) no altera las conclusiones del modelo final, ya que la variable con faltantes no fue seleccionada por los criterios de selección utilizados.

Índice

1	Manejo inteligente de datos faltantes	3
1.1	Referencia al análisis de faltantes de S1	3
1.2	Imputación mediante regresión lineal múltiple	3
1.3	Comparación de estrategias de imputación	3
2	Clasificación mediante regresión logística	4
2.1	Preparación de datos informada por S1	4
2.2	Selección de variables informada por S1 y S2	4
2.3	Evaluación de estabilidad mediante bootstrap	4
2.4	Diagnóstico de supuestos	5
2.5	Evaluación de desempeño predictivo	5
3	Análisis comparativo del impacto de la imputación	7
4	Informe integrado: síntesis S1 $\rightarrow$ S2 $\rightarrow$ S3	7
4.1	Metodología integrada	7
4.2	Resultados integrados	7
4.3	Discusión	7
4.4	Conclusiones y recomendaciones	8
5	Presentación del proyecto	8
6	Bibliografía	9

1. Manejo inteligente de datos faltantes

1.1 Referencia al análisis de faltantes de S1

En S1 se identificó que el dataset original no presenta valores faltantes; se generaron faltantes artificiales bajo mecanismo **MCAR** (12 %, `random_state=42`) en dos variables numéricas: **Curricular units 1st sem (grade)** y **Admission grade**. No se repite ese análisis; se usa como insumo directo. La matriz de correlaciones de S1 identificó a **Previous qualification (grade)** como el predictor más fuerte de **Admission grade** y a **Curricular units 2nd sem (grade)** como el más fuerte de **Curricular units 1st sem (grade)**, relaciones que se priorizan en la imputación (Tabla 1).

Conexión con evaluaciones anteriores

S2 validó que la imputación por media o KNN preserva la media original (sesgo < 0.1 %), mientras que la mediana sesga +2.05 % en variables con concentración de valores bajos. Esta evidencia justifica descartar la mediana como estrategia simple en la sección 1.3.

Variable objetivo	Predictor (matriz S1)	r
Admission grade	Previous qualification (grade)	0.581
Admission grade	Course	-0.132
Curricular units 1st sem (grade)	Curricular units 2nd sem (grade)	0.846
Curricular units 1st sem (grade)	Curricular units 1st sem (approved)	0.719

Tabla 1: Correlaciones de S1 usadas para seleccionar predictores de imputación (top 2 por variable).

1.2 Imputación mediante regresión lineal múltiple

Se imputa primero **Curricular units 1st sem (grade)** (predictores: calificación y unidades aprobadas del 2^{do} semestre, unidades aprobadas del 1^{er} semestre, evaluaciones del 1^{er} semestre) y luego **Admission grade** (predictores: **Previous qualification (grade)**, **Course**, **Application order**, calificaciones de 1^{er} y 2^{do} semestre), usando la primera ya completa como predictor de la segunda para no perder observaciones por faltantes cruzados. El modelo de **Curricular units 1st sem (grade)** obtiene $R^2 = 0.767$ (MAE= 1.63); el de **Admission grade**, $R^2 = 0.354$ (MAE= 8.22), moderado porque la única correlación fuerte disponible es **Previous qualification (grade)**. Los residuos no son estrictamente normales (Shapiro-Wilk $p < 0.001$), pero con $n > 3.000$ el error estándar de los coeficientes es confiable por el Teorema Central del Límite. Se imputaron 435 valores en cada variable (100 % de los faltantes), con sesgo frente al *ground truth* preservado de S1/S2 de +0.07 % (Admission grade) y +1.49 % (UC 1S grade).

1.3 Comparación de estrategias de imputación

Se comparan tres estrategias exclusivamente para **Admission grade** (la única que participa en el modelo de clasificación final, sección 2.1): **A** eliminación, **B** imputación simple (media) y **C** imputación por regresión (Tabla 2).

Estrategia	n	Media	Corr. con target	Corr. con Prev.Qual.Grade
A: Eliminación	3.195	127.26	0.123	0.581
B: Media	3.630	127.26	0.116	0.545
C: Regresión	3.630	127.27	0.127	0.596

Tabla 2: Comparación de estrategias de imputación para Admission grade.

Estrategia elegida: C. B y C preservan $n = 3.630$ frente a la pérdida del 12 % en A. Entre B y C, la regresión preserva mejor la correlación con **Previous qualification (grade)** y presenta

menor sesgo frente al *ground truth* (Figura 1). Se descarta la mediana por el sesgo de +2.05 % ya detectado en S2.




Figura 1: Distribución de Admission grade según estrategia de imputación.

2. Clasificación mediante regresión logística

2.1 Preparación de datos informada por S1

S2 identificó una colinealidad severa entre *Curricular units 1st sem (approved)* y *Curricular units 2nd sem (approved)* ($r = 0.92$, no ~ 0.7 como se leyó de forma aproximada en S1). Antes de decidir su tratamiento, se verifica esta colinealidad directamente en S3 mediante VIF: al incluir ambas variables junto a otros predictores candidatos, el VIF sube a un rango moderado-alto (UC1S= 6.30, UC2S= 8.35); al excluir UC1S, el VIF de UC2S cae a 2.68. La correlación recalculada sobre el dataset de trabajo es $r = 0.916$, consistente con S2. Esta verificación cuantitativa confirma la decisión de **excluir** *Curricular units 1st sem (approved)* del *pool* de predictores. Los outliers de variables de desempeño del 2^{do} semestre (S1: alta concentración en cero; S2: sensibilidad de la media de -5.7% al recorte 1 %-99 %) se tratan mediante **winsorización** al percentil 1 %-99 %, preservando el tamaño muestral. Partición 70/30 estratificada (`random_state=42`); estandarización ajustada solo sobre train.

2.2 Selección de variables informada por S1 y S2

Se construyen tres modelos sobre un *pool* de 19 candidatas: **M1** (5 predictores fijos de S1/S2: Beca, Matrícula al día, UC aprobadas 2S, Calificación 2S, Nota de admisión), **M2** (stepwise forward, $p < 0.05$) y **M3** (forward por BIC). M2 y M3 **convergen exactamente en el mismo modelo de 9 variables**: UC aprobadas 2S, UC matriculadas 2S, Matrícula al día, Beca, Deudor, Calificación 2S, modalidad de ingreso, carrera y género. Ninguno de los dos retiene *Admission grade*: una vez presente el desempeño del 2^{do} semestre, la nota de admisión no aporta señal incremental, coherente con que S2 ya la había identificado como la correlación más débil de las cinco evaluadas. En M1, *Tuition fees up to date* (OR= 22.4) y *Scholarship holder* (OR= 3.7) presentan los odds ratios más altos, en el mismo orden de fuerza que sus χ^2 en S1 (706.96 y 354.22).

Conexión con evaluaciones anteriores

La exclusión de UC 1S aprobadas y la priorización de Beca/Matrícula al día como predictores de referencia provienen directamente de la corrección de colinealidad y de la simulación Monte Carlo de S2.

2.3 Evaluación de estabilidad mediante bootstrap

Se aplica bootstrap (1.000 remuestras con reemplazo sobre train), replicando la técnica usada en S2 para validar los IC de S1, al modelo final (M2=M3). La Figura 2 muestra las distribuciones bootstrap de los 9 coeficientes junto a su IC del 95 %. Los IC bootstrap y los tradicionales (asintóticos de `statsmodels`) son muy similares (diferencias de ancho menores al 15 % en la mayoría de las variables); ningún IC bootstrap cambia de signo ni cruza el cero cuando el tradicional no lo hace,

por lo que no se identifican parámetros cualitativamente inestables. Esto reproduce la conclusión de S2: con tamaño de muestra grande, el bootstrap valida más que contradice los métodos clásicos.




Figura 2: Distribuciones bootstrap de los coeficientes del modelo final (1.000 remuestras).

2.4 Diagnóstico de supuestos

El VIF máximo del modelo final es moderado (variable de UC aprobadas 2S winsorizada); solo dos variables superan $VIF=3$ y ninguna supera 10, sin evidencia de multicolinealidad severa (esperable tras excluir UC 1S por la colinealidad de S2). La distancia de Cook máxima está muy por debajo de 1 (Figura 3); la fracción de observaciones que supera el umbral relativo $4/n$ es minoritaria y no concentrada en un patrón evidente. El test de Box-Tidwell detecta posible no linealidad en el logit para las variables de conteo (UC aprobadas y matriculadas 2S), consistente con su distribución concentrada en valores bajos ya documentada en S1/S2; se registra como limitación sin corregir, ya que no altera signo ni significancia de los coeficientes.




Figura 3: Distancia de Cook, modelo final ($M2 = M3$).

2.5 Evaluación de desempeño predictivo

Modelo seleccionado: M2 (stepwise), idéntico a M3 (BIC). Ambos superan a M1 en todas las métricas de test y tienen menor AIC (Tabla 3, Figura 4). Dado el contexto (identificación

Modelo	N. variables	AIC	Accuracy test	Recall test	AUC test
M1 (S1/S2)	5	1713.9	0.884	0.953	0.926
M2 (Stepwise)	9	1267.4	0.905	0.962	0.944
M3 (BIC)	9	1267.4	0.905	0.962	0.944

Tabla 3: Comparación de desempeño de los tres modelos (conjunto de prueba, $n = 1.089$).




Figura 4: Curvas ROC comparativas, conjunto de prueba.

temprana de estudiantes en riesgo, donde un falso negativo es más costoso que un falso positivo), se prioriza el **recall** como criterio de desempate junto al AUC; M2/M3 dominan también en esa métrica.

3. Análisis comparativo del impacto de la imputación

Se ajusta la misma arquitectura del modelo final sobre los tres datasets de la sección 1.3 (Tabla 4).

Estrategia	n	AIC	Accuracy test	AUC test
A: Eliminación	3.195	1136.0	0.906	0.946
B: Media	3.630	1267.4	0.905	0.944
C: Regresión	3.630	1267.4	0.905	0.944

Tabla 4: Impacto de la estrategia de imputación en el modelo final (M2 = M3).

¿Cambia las conclusiones? No. **Admission grade** no fue seleccionada por el modelo final (sección 2.2), por lo que **B y C producen resultados idénticos** (mismos coeficientes, AIC, accuracy y AUC), ya que solo difieren en una columna que el modelo no usa. Solo **A** difiere, y el cambio se explica enteramente por la reducción muestral (3.195 vs 3.630), no por un efecto de la imputación en sí. Se mantiene la recomendación de usar **C** como práctica metodológica general (menor sesgo frente al *ground truth*, sección 1.3), aunque en esta arquitectura específica el resultado sea equivalente a B. Esta conclusión es específica del modelo M2/M3; sería distinta si un modelo alternativo (p. ej. M1) retuviera **Admission grade** como predictor.

4. Informe integrado: síntesis S1 → S2 → S3

4.1 Metodología integrada

La metodología de S3 se construye en cada etapa sobre S1 y S2: la generación MCAR replica exactamente el mecanismo de S1 (**random_state=42**, dos variables, 12 %); los predictores de imputación provienen de la matriz de correlaciones de S1; el tratamiento de outliers (winsorización) responde a la sensibilidad de la media cuantificada en S2 (−5.7 %); la exclusión de UC 1S aprobadas del modelo de clasificación aplica directamente la corrección de colinealidad de S2 ($r = 0.92$), verificada de forma cuantitativa en S3 mediante VIF; y el bootstrap de coeficientes reutiliza la técnica de remuestreo validada en S2 para los IC de S1.

4.2 Resultados integrados

S1 identificó el rendimiento académico del 2^{do} semestre y las variables financieras (Beca, Matrícula al día) como los predictores más fuertes de deserción (t-Welch $p \approx 0$; $\chi^2 = 354.22$ y 706.96). **S2** validó por bootstrap los IC de S1, corrigió dos imprecisiones (colinealidad UC1S-UC2S: 0.92, no ~ 0.7 ; correlación de nota de admisión: 0.123, no 0.101) y confirmó, vía simulación Monte Carlo, que Beca y Matrícula al día ya explican gran parte de la tasa de graduación observada. **S3** tradujo estos hallazgos en un modelo de clasificación: el modelo final (M2=M3, 9 variables) alcanza AUC= 0.944 y recall= 0.962 en test, superando al modelo basado solo en los 5 predictores fijos de S1/S2 (AUC= 0.926), y su estabilidad queda confirmada por bootstrap sin parámetros cualitativamente inestables.

4.3 Discusión

El hallazgo más relevante de la integración es que la imputación de **Admission grade**, cuidadosamente fundamentada en S1/S2, termina siendo irrelevante para el modelo final porque esa variable no es seleccionada por los criterios stepwise/BIC: el desempeño académico del 2^{do} semestre domina la señal predictiva, tal como S1 ya sugería. Esto no invalida el trabajo de imputación (sí sería rele-

vante bajo una arquitectura como M1), pero ilustra que la relevancia de una decisión metodológica depende de la arquitectura final del modelo, no solo de la calidad del análisis de datos faltantes en sí.

4.4 Conclusiones y recomendaciones

1. Priorizar el seguimiento de matrícula al día y situación de beca/deudor como señales tempranas de riesgo administrativo-financiero.
2. Usar el desempeño académico del 2^{do} semestre como segunda línea de alerta, evitando la mediana como resumen en el grupo Dropout (S2).
3. Preferir el modelo M2/M3 (9 variables) sobre M1 (5 variables) por su mayor recall, dado el costo de no identificar a un estudiante en riesgo real.
4. No es necesario un método de imputación más sofisticado para Admission grade en esta arquitectura; sí sería recomendable revisarlo si se adopta un modelo que la incluya (p. ej. M1).

Limitaciones: posible no linealidad en el logit para variables de conteo (Box-Tidwell); validación con una única partición 70/30 (sin *k-fold* adicional); los faltantes son artificiales y las conclusiones sobre imputación no se extrapolan necesariamente a faltantes reales no aleatorios (MAR/MNAR).

5. Presentación del proyecto

La presentación expone el problema de deserción estudiantil, la metodología integrada $S1 \rightarrow S2 \rightarrow S3$, los resultados del modelo final (9 variables, $AUC = 0.944$) y las recomendaciones de la sección 4.4, enfatizando explícitamente cómo cada fase informó a la siguiente.

6. Bibliografía

- Efron, B., & Tibshirani, R. J. (1994). *An introduction to the bootstrap*. Chapman & Hall/CRC.
- Maidana, J. P. (2026). *Preparación de datos para modelamiento predictivo* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Diagnóstico de modelos de regresión: VIF, distancia de Cook y linealidad en el logit* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Regresión logística: odds ratios e interpretación* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Maidana, J. P. (2026). *Selección de variables: stepwise y criterios de información* [Apunte]. Universidad Andrés Bello, Santiago, Chile.
- Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict Students' Dropout and Academic Success* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>
- Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146. <https://doi.org/10.3390/data7110146>
- Seabold, S., & Perktold, J. (2010). Statsmodels: econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*.
- Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.